



УНИВЕРЗИТЕТ У НИШУ
ЕЛЕКТРОНСКИ ФАКУЛТЕТ



Аутоматско сумирање текстова на српском језику применом великих језичких модела

Семинарски рад

Студијски програм: Вештачка интелигенција и машинско учење

Предмет: Обрада природних језика

Студент:
Стефан Стојиљковић, бр. инд. 1952

Ментор:
Проф. др Сузана Стојковић

Ниш, септембар 2026. Година

Садржај

1. Увод	3
1.1 Обрада природних језика	3
1.2 Сумаризација текстова	3
2. Аутоматско сумирање текста.....	4
2.1 Дефиниција	4
2.2 Extractive сумирање	5
2.3 Abstractive сумирање	7
2.4 Метрике евалуације	9
3. Модели и методе за аутоматско сумирање	10
3.1 TF-IDF	10
3.2 TextRank.....	10
3.3 Трансформер архитектура.....	11
3.4 Велики језички модели.....	15
4. Експеримент	16
4.1 Скуп података.....	16
4.2 Обрада.....	17
4.3 Евалуација.....	17
4.4 Дискусија	19
5. Закључак	19

1. Увод

1.1 Обрада природних језика

Обрада природног језика (NLP) је подблaст рачунарства и вештачке интелигенције (AI) која користи машинско учење како би омогућила рачунарима да разумеју и комуницирају људским језиком [1].

НЛП омогућава рачунарима и дигиталним уређајима да препознају, разумеју и генеришу текст и говор комбинујући рачунарску лингвистику, моделирање људског језика засновано на правилима, заједно са статистичким моделирањем, машинским учењем и дубоким учењем.

НЛП олакшава људима комуникацију и сарадњу са машинама, омогућавајући им да то чине природним људским језиком који користе свакодневно. Ово нуди предности у многим индустријама и применама: Аутоматизација понављајућих задатака, Побољшана анализа података и увиди, Побољшана претрага, Генерисање садржаја [1].

1.2 Сумаризација текстова

Сумирање текста сажима један или више текстова у краће резимее ради побољшаног издвајања информација [2].

Аутоматско сумирање текста (или сумирање докумената) је метода обраде природног језика која кондензује информације из једног или више улазних текстуалних докумената у оригинални излазни текст. Алгоритми за сумирање текста често користе архитектуре дубоког учења, трансформаторе за анализу докумената и генерисање текстуалних резимеа.

Најочигледнија примена сумирања текста је убрзано истраживање. Ово има потенцијалну употребу у разним областима, као што су правна, академска и маркетиншка. Истраживачи такође показују како трансформери сумирања текста могу унапредити додатне задатке. Најчешћа примена сумирања текстова је код сумирања вести и превођења са једног језика на други [2].

2. Аутоматско сумирање текста


2.1 Дефиниција

Аутоматско сумирање текста, такође познато као аутоматско сумирање или компресија текста, је техника која се користи за сажимање велике количине текста у краћу, сажетију верзију, уз очување најважнијих информација [3].

Значај аутоматског сумирања текста лежи у његовој способности да уштеди време и побољша ефикасност у претраживању информација. У данашњем свету где информација има у изобиљу, сумирање помаже у смањењу преоптерећења информацијама и побољшању читљивости и разумевања.

Аутоматско сумирање текста је процес аутоматског генерисања сажете верзије великог текстуалног документа, уз задржавање најважнијих информација [3]. Може се грубо класификовати у три типа: екстрактивно, апстрактно и хибридно. Екстрактивно сумирање подразумева одабир и спајање важних реченица или фраза из оригиналног текста. Апстрактно сумирање подразумева генерисање новог сумирања које се разликује од оригиналног текста. Хибридно сумирање је комбинација екстрактивног и апстрактног сумирања.

Технике које се користе у аутоматском сумирању текста укључују обраду природног језика, машинско учење и дубоко учење. Обрада природног језика се користи за анализу структуре и значења текста, док се алгоритми машинског учења користе за идентификацију најважнијих реченица или фраза. Технике дубоког учења, као што су неуронске мреже, користе се за генерисање новог резимеа који се разликује од оригиналног текста. Помоћу ових техника, могуће је произвести висококвалитетне резимее који су и сажети и информативни.



Слика 2.1.1: Дијаграм сумирања текста [3].

Аутоматско сумирање текста је кључни алат у данашњем свету богатом информацијама. Са све већом количином података, сумирање је постало неопходно за уштеду времена и побољшање ефикасности. Ево неких од кључних предности истог [3]:

- Штеди време тако што велику количину текста сажима у краћу, лакшу за коришћење верзију.
- Побољшава претраживање информација тако што истиче најважније делове текстуалног документа.
- Побољшава читљивост и разумевање представљајући најважније информације у сажетом и лако разумљивом формату.
- Смањује преоптерећење информацијама филтрирањем небитних информација и приказивањем само најважнијих делова текстуалног документа.

Аутоматско сумирање текста је моћна функција која има потенцијал да револуционише начин на који обрађујемо и управљамо информацијама. Од уштеде времена и побољшања ефикасности до смањења преоптерећења информацијама и побољшања читљивости, предности исте су јасне.

2.2 Extractive сумирање

Екстрактивно сумирање издваја неизмењене реченице из оригиналних текстуалних докумената. Кључна разлика између екстрактивних алгоритама је начин на који бодују важност реченица, а истовремено смањују тематску редувантност. Разлике у бодовању реченица одређују које реченице треба издвојити, а које задржати [1].

Као и код других NLP задатака, сумирање текста захтева да текстуални подаци прво прођу претходну обраду. То укључује токенизацију, уклањање зауставних речи и лематизацију или стеминг како би скуп података био читљив моделу машинског учења. Након претходне обраде, све методе екстрактивног сумирања текста прате три општа, независна корака: репрезентацију, бодовање реченица и избор реченица.

Репрезентација [1]: У фази репрезентације, алгоритам сегментира и представља претходно обрађене текстуалне податке за поређење. Многе од ових репрезентација се граде од модела „вреће речи“, који представљају текстуалне сегменте, као што су речи или реченице, као тачке података у векторском простору. Велики скупови података са више докумената могу користити термин фреквенција-инверзна фреквенција документа (TF-IDF), варијанту модела „вреће речи“ која пондерише сваки термин како би одражавала његов значај унутар скупа текста.

Алати за моделирање тема као што је латентна семантичка анализа (LSA) су још једна метода представљања која производи групе резимираних кључних речи распоређених по документима. Други алгоритми, као што су LexRank и TextRank, користе графове. Ови

приступи засновани на графовима представљају реченице као чворове (или врхове) који су повезани линијама према резултатима семантичке сличности.


Бодовање реченица [1]: Бодовање реченица, као што му име каже, бодује сваку реченицу у тексту према њеном значају за тај текст. Различити прикази примењују различите методе бодовања. На пример, приступи представљања тема бодују сваку реченицу према степену у којем оне појединачно изражавају или комбинују кључне теме.

Конкретније, ово може укључивати тежинско распоређивање реченица према кофреквенцији кључних речи теме. Приступи засновани на графовима, израчунавају централност реченице. Ови алгоритми одређују централност користећи TF-IDF да би израчунали колико далеко дати чвор реченице може бити од центроида документа у векторском простору.

Избор реченице [1]: Последњи општи корак у екстрактивним алгоритмима је избор реченица. Након што су реченице пондерисане по важности, алгоритми бирају n најважнијих реченица за документ или колекцију истих. Ове реченице чине генерисани резиме. Али шта ако постоји семантичко и тематско преклапање у овим реченицама?

Корак селекције реченица има за циљ смањење сувишности у коначним резимеима. Методе максималне маргиналне релевантности користе итеративни приступ. Конкретно, оне поново израчунавају оцене важности реченица у складу са сличношћу те реченице са већ одабраним реченицама. Глобалне методе селекције бирају подскуп најважнијих реченица како би се максимизирала укупна важност и смањила сувишност.

Као што овај преглед илуструје, екстрактивно сумирање текста је у крајњој линији питање рангирања текста (а најчешће, реченица). Технике екстрактивног сумирања текста рангирају документе и њихове тест низове (за узорак, реченице) по редоследу или производе резиме који најбоље одговара централним темама идентификованим у датим текстовима. На овај начин, екстрактивно сумирање се може схватити као облик претраживања информација.



Слика 2.2.1: Дијаграм екстрактивног сумирања [4].

2.3 Abstractive сумирање

Апстрактивно сумирање генерише оригиналне суме користећи реченице које се не налазе у оригиналним текстуалним документима. Такво генерисање захтева неуронске мреже и велике језичке моделе (LLM) да би се произвеле семантички значајне текстуалне секвенце [1].

Технике апстрактивног сумирања текста користе неуронске мреже за генерисање оригиналног текста који сумира један или више докумената. Иако постоје бројне врсте метода апстрактивног сумирања текста, литература не користи ниједан свеобухватни систем класификације за описивање ових метода. Ипак, могуће је дати преглед општих циљева ових различитих метода.

Компресија реченица [1]: Као и код многих примена вештачке интелигенције, апстрактивно сумирање текста у крајњој линији има за циљ да опонаша људски генерисане суме. Једна кључна карактеристика овог другог је компресија реченица, људи сумирају дуже текстове и реченице скраћујући их. Постоје два општа приступа компресији реченица: методе засноване на правилима и статистичке методе.

Први користе синтаксичко знање за анализу граматичких сегмената. Ови користе кључне речи, синтаксичке трагове или чак ознаке делова речи да би издвојили делове текста који се затим спајају, често према унапред дефинисаном шаблону. Овај шаблон се може преузети из додатне аутоматизоване анализе текста или кориснички дефинисаних правила.


У статистичким приступима, модел (било да је добијен претходним тренирањем или финим подешавањем) учи које сегменте реченица треба уклонити. На пример, парсер стабла

може идентификовати сличне реченице из улазног текста и попунити упоредиве реченице у структури стабла. Стабло зависности је једна таква структура која моделира реченице према перципираном односу између речи, усклађујући се са распоредом субјекат-предикат. Реченица у овој структури може имати глагол као централни чвор, са субјектима и објектима (то јест, именицама) и везницима који се гранају. Додатни глаголи ће се затим гранати од именица којима су везани. Када је текст представљен у структури стабла, алгоритам затим бира уобичајене речи или фразе за употребу од стране генеративне мреже при креирању новог резимеа.

Фузија информација [1]: Фузија информација је још један кључни аспект апстрактивног сумирања. Људи сумирају документе спајањем информација из више одломака у једну реченицу или фразу. Један предложени приступ за имитирање овога је фузија реченица у скупу од више докумената. Овај приступ идентификује уобичајене фразе у скупу докумената и спаја их помоћу технике која се назива решетчасто израчунавање како би се добио граматички кохерентан енглески резиме.

Друга предложена метода користи неуронске тематске моделе за генерисање кључних термина који заузврат воде генерисање резимеа. У овом приступу, уобичајене кључне речи које покривају главне тачке у више докумената комбинују се у једну реченицу или групу реченица.

Информативни налог [1]: Коначна брига код апстрактивног сумирања текста је редослед информација. Сумиране информације не прате нужно исти редослед као и оригинални изворни документ. Када људи пишу сумирања, на пример, често могу тематски организовати информације. Једна метода која се користи за тематску организацију су кластери. Конкретно, издвојене реченице су организоване у кластере према тематском садржају (како је одређено кључним речима које се истовремено јављају). У том смислу, неуронски тематски модели су још један потенцијални приступ тематском уређивању информација.



Слика 2.3.1: Дијаграм апстрактивног сумирања [4].

2.4 Метрике евалуације

BLEU (билингвални евалуациони подсетник) је метрика евалуације која се често користи у машинском превођењу. Она мери сличност између истините тачке гледишта и излаза модела за низ од n речи, познатих као n -грами. У сумирању текста, BLEU мери колико често и у којој мери се n -грами у аутоматском сумирању преклапају са онима у људски генерисаном сумирању, узимајући у обзир погрешна понављања речи у првом. Затим користи ове резултате прецизности за појединачне n -граме да би израчунао укупну прецизност текста, познату као геометријска средња прецизност. Ова коначна вредност је између 0 и 1, при чему друга указује на савршено поклапање између машински и људски генерисаних текстуалних сумирања [1].

ROUGE (recall-oriented understudy for gisting evaluation) је изведен из BLEU посебно за процену задатака сумирања. Као и BLEU, упоређује машинске резимее са људски генерисаним резимеима користећи n -грама. Али док BLEU мери машинску прецизност, ROUGE мери машинско памћење. Другим речима, ROUGE израчунава тачност аутоматског резимеа према броју n -грама из људски генерисаног резимеа пронађеног у аутоматском резимеу. ROUGE резултат, као и BLEU, је било која вредност између 0 и 1, при чему ово друго указује на савршено поклапање између машински и људски генерисаних текстуалних резимеа [1].

3. Модели и методе за аутоматско сумирање

3.1 TF-IDF

У области обраде природног језика, TF-IDF (фреквенција термина - инверзна фреквенција докумената) је моћна техника која се користи за анализу и разумевање важности речи у корпусу докумената. TF-IDF игра кључну улогу у задацима као што су анализа текста, претраживање информација и класификација докумената [5].

TF-IDF је нумеричка статистика која одражава значај речи у документу у односу на колекцију докумената, познату као корпус. Идеја иза TF-IDF-а је да се квантификује важност термина у документу у односу на његову учесталост у документу и његову реткост у више докумената.

Учесталост термина (TF): TF мери учесталост појављивања термина у документу. Израчунава се као однос броја пута када се термин појављује у документу и укупног броја појављивања термина у том документу. Циљ је да се истакну речи које су честе у документу.

Инверзна фреквенција докумената (IDF): IDF мери реткост термина у колекцији докумената. Израчунава се као логаритам односа укупног броја докумената и броја докумената који садрже тај термин. Циљ је да се кажњавају речи које су уобичајене у свим документима.

TF-IDF резултат за термин у документу се добија множењем његових TF и IDF резултата [5]:

$$TF - IDF(t, d, D) = TF(t, d) * IDF(t, D)$$

3.2 TextRank

У данашњем свету вођеном вештачком интелигенцијом, способност сумирања и издвајања кључних информација из великих количина текста је кључна. Један моћан, али често потцењен алгоритам за ово је TextRank, алгоритам заснован на графовима инспирисан Google-овим PageRank-ом, али дизајниран за задатке обраде природног језика попут сумирања и издвајања кључних речи [6].

TextRank је ненадгледани, једноставан за имплементацију и изузетно ефикасан. Чини основу многих екстрактивних сумирача спремних за продукцију и имплементиран је у неколико популарних Пајтон библиотека. Независан је од домена, не захтева податке за обуку и истиче се у условима где су интерпретабилност и ниски захтеви за ресурсима важни.

TextRank користи модел заснован на графовима где су текстуалне јединице, речи или реченице, чворови, а ивице представљају односе као што су заједничко појављивање (за

речи) или сличност (за реченице). Алгоритам затим примењује PageRank на овај граф како би утврдио који су чворови (речи/реченице) најцентралнији или „важнији“ [6].

Док PageRank процењује важност веб страница на основу структуре хиперлинкова, TextRank ради исто са језиком, додељује већи значај текстуалним елементима који су централни у њиховом језичком контексту. Ово рекурзивно израчунавање бележи „утицај“ сваке јединице на основу њених суседа, чинећи приступ глобално свесним.

TextRank има две основне апликације [6]: Издвајање реченица и Издвајање кључних речи. Поступак издвајања реченица:

- Подели текст на појединачне реченице.
- Израчуна сличност реченица, често користећи косинусну сличност преко TF-IDF вектора.
- Конструише граф са реченицама као чворовима и сличностима као тежинама ивица.
- Покреће PageRank да оцени сваку реченицу.
- Изабере најбоље рангиране реченице као резиме.

Поступак издвајања кључних речи:

- Издвоји кандидате за кључне речи (нпр. именице и придеве).
- Направи граф где су чворови речи, а ивице повезују речи које се истовремено јављају унутар прозора.
- Покреће PageRank да додели оцене важности.
- Изабере речи или фразе са највише ранжираних места.

TextRank често служи као основа за екстрактивно сумирање. TextRank остаје моћна основа у NLP алатима. Једноставан је за имплементацију, интерпретабилан и не захтева означене податке, што га чини идеалним за брзе увиде и производне процесе.

3.3 Трансформер архитектура

Трансформер модел је врста архитектуре неуронске мреже која се истиче у обради секвенцијалних података, а најистакнутије је повезана са моделима великих језика (LLM). Трансформер модели су такође постигли врхунске перформансе у другим областима вештачке интелигенције (AI), као што су рачунарски вид, препознавање говора и предвиђање временских серија [7].

Првобитно представљени као еволуција модела секвенци-по-секвенци заснованих на рекурентним неуронским мрежама (RNN) који се користе за машинско превођење, модели засновани на трансформерима су од тада достигли врхунски напредак у скоро свакој дисциплини машинског учења (ML). Упркос својој свестраности, трансформер модели се и даље најчешће разматрају у контексту случајева употребе обраде природног језика (НЛП), као што су четботови, генерисање текста, сумирање, одговарање на питања и анализа расположења.

Трансформер модели, као што су релационе базе података, генеришу векторе упита, кључева и вредности за сваки део низа података и користе их за израчунавање тежина пажње кроз низ множења матрица. Релационе базе података су дизајниране да поједноставе складиштење и преузимање релевантних података: оне додељују јединствени идентификатор („кључ“) сваком податку, а сваки кључ је повезан са одговарајућом вредношћу [7].

Вектор упита представља информације које одређени токен „тражи“. Другим речима, вектор упита токена се користи за израчунавање како други токени могу утицати на његово значење, конјугацију или конотације у контексту.

Вектори кључева представљају информације које сваки токен садржи. Поравнање између упита и кључа се користи за израчунавање тежина пажње које одражавају колико су релевантни у контексту тог текстуалног низа.

Вредност (или вектор вредности) „враћа“ информације из сваког вектора кључева, скалиране према његовој одговарајућој тежини пажње. Доприноси кључева који су снажно усклађени са упитом имају већу тежину; доприноси кључева који нису релевантни за упит биће тежи ближи нули.

Токенизација и уградња уноса [7]: Док су знакови, слова, бројеви или интерпункцијски знаци, основне јединице које ми људи користимо за представљање језика, најмања јединица језика коју користе модели вештачке интелигенције је токен. Сваком токenu је додељен ИД број, а ови ИД бројеви (а не речи или чак сами токени) су начин на који се LLM-ови крећу кроз своју „базу података“ речника. Ова токенизација језика значајно смањује рачунарску снагу потребну за обраду текста.

Да би се генерисали вектори упита и кључева који ће се уносити у слојеве пажње трансформера, моделу је потребно почетно, бесконтекстно уграђивање вектора за сваки токен. Ова почетна уграђивања токена могу се научити током обуке или узети из претходно обученог модела уграђивања речи.

Позиционо кодирање [7]: Редослед и положај речи могу значајно утицати на њихова семантичка значења. Док серијализована природа рекурентних неуронских мрежа инхерентно чува информације о положају сваког токена, трансформер модели морају експлицитно додати информације о положају да би механизам пажње могао да их узме у обзир.

Код позиционог кодирања, модел додаје вектор вредности сваком уграђивању токена, изведен из његовог релативног положаја, пре него што улаз уђе у механизам пажње. Што су два токена ближа, то ће њихови позициони вектори бити сличнији и самим тим ће се њихов резултат поравнања више повећавати додавањем позиционих информација. Модел тако учи да обрађа већу пажњу на оближње токене.

Генерисање вектора упита, кључева и вредности [7]: Када се додају информације о позицији, свако ажурирано уграђивање токена се користи за генерисање три нова вектора. Ови вектори упита, кључа и вредности генеришу се пропуштањем оригиналних уграђивања токена кроз сваки од три паралелна слоја неуронске мреже са унапредном везом који

претходе првом слоју пажње. Сваки паралелни подскуп тог линеарног слоја има јединствену матрицу тежина, научену кроз самонадгледано претходно тренирање на огромном скупу података текста.

- Уграђивања се множе матрицом тежина W_Q да би се добили вектори упита (Q), који имају d_k димензије.
- Уграђивања се множе матрицом тежина W_K да би се добио вектор кључа (K), такође са димензијама d_k .
- Уграђивања се множе матрицом тежина W_V да би се добили вектори вредности (V), са димензијама d_v .

Рачунање самопажње [7]: Примарна функција механизма пажње трансформера је да додели тачне тежине пажње упаривањима вектора упита сваког токена са кључним векторима свих осталих токена у низу. Када се то постигне, можете замислити сваки токен x као да сада има одговарајући вектор тежина пажње, у којем сваки елемент тог вектора представља степен у којем би неки други токен требало да утиче на њега.

- Вектор вредности сваког другог токена се сада множи са његовом одговарајућом тежином пажње.
- Ови вектори вредности пондерисани пажњом се сумирају. Резултујући вектор представља агрегиране контекстуалне информације које се токenu x пружају од стране свих осталих токена у низу.
- Коначно, резултујући вектор промена пондерисаних пажњом из сваког токена се додаје оригиналном, постпозиционом вектору кодирања токена x .

У суштини, уграђивање вектора x је ажурирано како би боље одражавало контекст који пружају остали токени у низу.

Multi-head пажња [7]: Да би обухватили многе вишеслојне начине на које се токени могу међусобно повезати, трансформер модели имплементирају пажњу више глава у више блокова пажње. Пре него што се унесе у први слој унапред, свако оригинално уграђивање улазног токена се дели на h једнаких подскупова. Сваки део уграђивања се уноси у једну од h паралелних матрица тежина Q, K и V, од којих се свака назива глава упита, кључна глава или вредносна глава. Вектори које избацује сваки од ових паралелних триплета глава упита, кључа и вредности се затим уносе у одговарајући подскуп следећег слоја пажње, који се назива глава пажње.

У завршним слојевима сваког блока пажње, излази ових h паралелних кола се на крају поново спајају пре него што се пошаљу следећем слоју за унапред праћење. У пракси, обука модела резултира тиме да свако коло учи различите тежине које обухватају посебан аспект семантичких значења.


Резидуалне везе и нормализација слојева [7]: У неким ситуацијама, прослеђивање контекстуално ажурираног излаза уграђивања од стране блока пажње може довести до неприхватљивог губитка информација из оригиналне секвенце. Да би се ово решило, трансформер модели често уравнотежују контекстуалне информације које пружа

механизам пажње са оригиналним семантичким значењем сваког токена. Након што се подскупови уграђивања токена ажурирани пажњом поново споје, ажурирани вектор се затим додаје оригиналном (позиционо кодираном) векторском уграђивању токена. Оригинално уграђивање токена обезбеђује резидуална веза између тог слоја и ранијег слоја мреже.

Добијени вектор се уноси у други линеарни слој за унапредно прослеђивање, где се нормализује назад на константну величину пре него што се проследи следећем блоку пажње. Заједно, ове мере помажу у очувању стабилности у обуци и осигуравају да се оригинално значење текста не изгуби како се подаци крећу дубље у неуронску мрежу.

Генерисање излаза [7]: На крају, модел има довољно контекстуалних информација да информише своје коначне излазе. Природа и функција излазног слоја зависиће од специфичног задатка за који је модел трансформера дизајниран.

Трансформер модели се најчешће повезују са NLP-ом, будући да су првобитно развијени за случајеве употребе машинског превођења. Најзначајније је да је трансформерска архитектура довела до великих језичких модела (LLM) који су катализовали појаву генеративне вештачке интелигенције. Информације које пружа механизам самопажње омогућавају моделу да извуче контекст из улазне секвенце и одржи кохерентност и континуитет свог излаза.



Слика 3.3.1: Дијаграм трансформер модела.

3.4 Велики језички модели

Велики језички модели (LLM) су категорија модела дубоког учења обучених на огромним количинама података, што их чини способним да разумеју и генеришу природни језик и друге врсте садржаја за обављање широког спектра задатака. LLM-ови су изграђени на врсти архитектуре неуронске мреже која се назива трансформер, а која се истиче у обрађивању низова речи и хватању образаца у тексту [8].

LLM-ови раде као огромне машине за статистичко предвиђање које више пута предвиђају следећу реч у низу. Оне уче обрасце у свом тексту и генеришу језик који прати те обрасце.

Обука почиње са огромном количином података, милијардама или трилионима речи из књига, чланака, веб страница, кода и других текстуалних извора. Овај текст се током процеса „токенизације“ дели на мање, машински читљиве јединице које се називају „токени“. Токени су мање јединице као што су речи, подречи или знакови. Ово стандардизује језик тако да се ретке и нове речи могу доследно обрађивати.

Модел пропушта токене кроз трансформер мрежу. Трансформер модели, представљени 2017. године, корисни су због свог механизма самопажње, који им омогућава да „обрате пажњу“ на различите токене у различитим тренуцима. Ова техника је централни део трансформера и његова главна иновација. Самопажња је делимично корисна зато што омогућава вештачкој интелигенцији модел да израчуна односе и зависности између токена, посебно оних који су удаљени један од другог у тексту. Трансформер архитектуре такође омогућавају паралелизацију, чинећи процес много ефикаснијим од претходних метода. Ови квалитети су омогућили LLM-овима да обрађују невиђено велике скупове података [8].

Када се текст подели на токене, сваки токен се мапира на вектор бројева који се назива уграђивање. Неуронске мреже се састоје од слојева вештачких неурона, где сваки неурон извршава математичку операцију. Трансформатори се састоје од многих ових слојева, и на сваком од њих се уграђивања мало подешавају, постајући богатије контекстуалне репрезентације од слоја до слоја.

Једном обучени, модели великих језика раде тако што одговарају на упите токенизацијом упита, претварањем у уграђене елементе и коришћењем његовог трансформера за генерисање текста један по један токен, израчунавањем вероватноћа за све потенцијалне следеће токене и приказивањем највероватнијег. Овај процес, назван инференција, понавља се док се излаз не заврши. Модел „не зна“ коначан одговор унапред; користи све статистичке односе које је научио током обуке да би предвидео један токен у једном тренутку, правећи своју најбољу претпоставку у сваком кораку.

LLM-ови редефинишу пословне процесе и доказале су своју свестраност у мноштву случајева употребе у многим индустријама [8]:

Генерисање текста: могу да обављају све врсте задатака креирања садржаја као што су израда имејлова, блог постова или правних дописника као одговор на захтеве.

Сумирање текста: могу да сумирају дугачке чланке, вести, истраживачке извештаје, корпоративну документацију и историју купаца у темељне текстове прилагођене дужини жељеном излазном формату и стилу.

АИ асистенти: Четботови покретани конверзационом АИ могу да одговарају на питања и пружају детаљне информације као део интегрисаног решења за корисничку подршку у реалном времену.

Анализа расположења: Анализира се тон купаца како би се боље разумеле повратне информације купаца у већем обиму.

Превод језика: Аутоматизовани превод пружа ширу покривеност организацијама на различитим језицима и географским подручјима са течним преводима и вишејезичним могућностима.

LLM-ови су моћни алати, али долазе са неколико ограничења. Једна од главних брига је тачност. Током халуцинација, модел генерише информације које су лажне или обмањујуће, а звуче вероватно. LLM-ови такође могу да одражавају и појачавају пристрасности присутне у њиховим подацима за обуку, производећи излазе који су неправедни или увредљиви. Поред тога, њихови захтеви за ресурсима су значајни: обука и покретање LLM-ова захтевају велике количине рачунарске снаге и енергије, што подиже и забринутост у погледу трошкова и животне средине.

4. Експеримент

4.1 Скуп података

Као скуп података у експериментисању искоришћени су пет чланака са википедије. Ових пет чланака говоре редом о: вештачкој интелигенцији, Николи Тесли, Србији, интернету и Нишу.

Свих пет страница је на ћирилици, па самим тим је неопходно извршити транслитерацију у латиницу. Пар основних карактеристика ових страница су дати у наредној табели:

страница	број речи	број знакова	број реченица у поглављу
Вештачка Интелигенција	13380	86141	913
Никола Тесла	5756	35551	217
Србија	17603	108323	716
Интернет	3160	20904	258
Ниш	9993	60148	324

4.2 Обрада

За сумирање текстова искоришћени су TextRank, трансформер модел и велики језички модел. За трансформер модел узет је „csebuetnlp/mT5_multilingual_XLSum”, а за велики језички модел узет је “llama3.1:8b” повучен локално преко Ollama-e.

TextRank се показао веома добрим са дугачким пасусима. Пасуси су сложени, реченице су граматички исправне, логичне и разумљиве. Лоша страна је хаос између самих реченица јер се многе не надовезују једна на другу.

Трансформер модел се показао изузетно лошим јер на излазу даје само једну реченицу која ручном евалуацијом не чини сам срж сумираног садржаја.

Велики језички модел се такође добро показао као и TextRank, али у односу на TextRank пасуси су мањи. Иако су пасуси мањи они су тачнији, представљене реченице су информационо битније.

Код сумирања странице за интернет, модел је халуцинирао. После прве реченице модел је готово у недоглед понављао четири-пет фраза. Поновним покретањем сумирања халуцинација се није решила, већ сваки пут исто. Халуцинација се објашњава тиме што је за све остале странице модел одрадио сумирање у свега неколико секунди док је за ову страницу било потребно неколико минута.

4.3 Евалуација

Сваки генерисани резиме се бодује у односу на уводни пасус Википедије документа помоћу F-мера “ROUGE-1”, “ROUGE-2” и “ROUGE-L” стандардних метрика преклапања n-грама за сумирање. Додате су још две дијагностичке мере без референци јер сам ROUGE мало говори о како метод сумира:

- `compression_ratio` (степен компресије) - резиме дужине / дужина изворног текста (нижи = више компресован),
- `novel-unigram ratio` (однос романа и униграма) - део речи у резимеу које се не појављују у изворном тексту (0 за чисто екстрактивну методу по конструкцији; веће вредности указују на више парафразирања, а такође и више простора за модел да уведе неподржан садржај).

Сви резултати су наведени у наредној табели:

doc_id	method	rouge1	rouge2	rougeL	compression_ratio	novel_unigram_ratio
doc_00	textrank	0.402	0.117	0.153	0.064	0.000
doc_00	transformer	0.033	0.008	0.029	0.001	0.250
doc_00	llm	0.113	0.032	0.067	0.007	0.333
doc_01	textrank	0.283	0.047	0.136	0.028	0.000
doc_01	transformer	0.044	0.009	0.044	0.002	0.000
doc_01	llm	0.344	0.064	0.172	0.030	0.215
doc_02	textrank	0.219	0.032	0.097	0.015	0.000
doc_02	transformer	0.006	0.000	0.006	0.000	0.600
doc_02	llm	0.116	0.012	0.068	0.008	0.117
doc_03	textrank	0.258	0.044	0.118	0.044	0.000
doc_03	transformer	0.111	0.029	0.082	0.009	0.286
doc_03	llm	0.108	0.000	0.048	0.018	0.000
doc_04	textrank	0.358	0.064	0.155	0.023	0.000
doc_04	transformer	0.050	0.011	0.039	0.001	0.200
doc_04	llm	0.183	0.037	0.128	0.008	0.308

Методе се упоређују на основу средњих ROUGE резултата и времена извршавања, након чега следи упарени Вилкоксонев тест означених рангова на ROUGE-1 (упарени по документу, пошто свака метода сумира исте документе).

	rouge1	rouge1	rouge2	rouge2	rougeL	rougeL	compression_ratio	compression_ratio	novel_unigram_ratio	novel_unigram_ratio	runtime_sec	runtime_sec
method	mean	std	mean	std	mean	std	mean	std	mean	std	mean	std
llm	0.173	0.101	0.029	0.025	0.097	0.052	0.014	0.010	0.194	0.138	2.133	0.710
textrank	0.304	0.075	0.061	0.033	0.132	0.025	0.035	0.020	0.000	0.000	0.027	0.018

transformer	0.049	0.039	0.011	0.011	0.040	0.028	0.003	0.003	0.267	0.216	2.839	0.910
-------------	-------	-------	-------	-------	-------	-------	-------	-------	-------	-------	-------	-------

4.4 Дискусија

О самим методама. TextRank-у нису потребни подаци за обуку или GPU и производи граматички савршене (јер нису модификоване) српске реченице, али може само да рекомбинује постојеће реченице, не може да компресује идеју која је раширена преко неколико реченица у једну. mT5-XLSum трансформатор и подстакнути LLM могу, у принципу, слободно да парафразирају и компресују, што је управо разлог зашто су одабрани за ово поређење.

О евалуацији. Коришћење уводног пасуса са Википедије као резимеа референце је згодна замена без трошкова анотације. Такође пристрасно поређење усмерава ка екстрактивним резултатима, јер сам уводни пасус пишу људи који су изабрали специфичне речи које апстрактивни модел нема разлога да тачно репродукује. ROUGE ово погоршава: награђује тачно преклапање n-грама и слеп је за парафразе, што је много већи проблем за српски него за енглески језик управо због богате морфологије језика. Праведније поређење би додало метрику засновану на уграђивању као што је BERTScore са енкодером који је свестан српског или словенског језик.

5. Закључак

Овај семинарски је изградио свеобухватни, репродуктивни цевовод за поређење екстрактивног, трансформерски заснованог и LLM-базираног сумирања на српском веб тексту: преузимање са принципијелном конструкцијом референци-сумирања (Википедијин увод наспрам тела), претходна обрада специфична за српски језик (нормализација скрипте, прилагођена листа зауставних речи, разделилац реченица без зависности), три сумирача и вишеугаона евалуација (ROUGE, компресија, апстрактност, време извршавања, анализа грешака, осетљивост на дужину).

Будући рад би укључио: Значајно проширити корпус и диверзификовати изворе ван Википедије, Додати метрику евалуације која је свесна српског језика (BERTScore са BERTic/classla или лематизовани ROUGE) да би се решио проблем морфологије, Испробати одговарајући српски разделник/токенизатор реченица (classla) уместо хеуристике регуларних израза која се овде користи и размислити о фином подешавању трансформера на српским подацима уместо ослањања на вишејезичну контролну тачку од 45 језика, Избор већег броја великих језичких модела уместо ослањања на само један.

Литература

- [1] Stryker, C., & Holdsworth, J. (2024, November 28). *What is NLP (natural language processing)?*. IBM. <https://www.ibm.com/think/topics/natural-language-processing>
- [2] Murel, J., & MurelKavlakoglu, J. (2024, November 27). *What is text summarization?*. IBM. <https://www.ibm.com/think/topics/text-summarization>
- [3] *Importance & Benefits of Auto Text Summarization*. (2023, February 16). Medium. <https://medium.com/@researchworkai/importance-benefits-of-auto-text-summarization-64f04bc5b7fc>
- [4] Jain, D., Borah, M. D., & Biswas, A. (2021). Summarization of legal documents: Where are we now and the way forward. *Computer Science Review*, 40, 100388. <https://doi.org/10.1016/j.cosrev.2021.100388>
- [5] Jain, A. (2024, February 4). *TF-IDF in NLP (Term Frequency Inverse Document Frequency)*. Medium. <https://medium.com/@abhishekjainindore24/tf-idf-in-nlp-term-frequency-inverse-document-frequency-e05b65932f1d>
- [6] Erraji, Y. (2025, June 19). *Understanding TextRank : A Deep Dive into Graph-Based Text Summarization and Keyword Extraction*. Medium. <https://medium.com/@yassineerraji/understanding-textrank-a-deep-dive-into-graph-based-text-summarization-and-keyword-extraction-905d1fb5d266>
- [7] Bergmann, C. S. D. (2026, March 18). *What is a transformer model?* <https://www.ibm.com/think/topics/transformer-model>
- [8] Stryker, C. (2026, July 24). *What are Large Language Models (LLMs)?* | IBM. <https://www.ibm.com/think/topics/large-language-models>